

Guia de Estudo Didático — O Estudo CorePAM, do Zero

Para: Rafael de Negreiros Botan

Objetivo: Entender cada ideia do estudo CorePAM de forma tão clara que você possa explicar para qualquer pessoa — um médico sem formação em estatística, um estatístico sem formação em oncologia, ou um leigo curioso.

Regra deste guia: Nada de jargão sem tradução. Nada de sigla sem explicação prévia. Cada conceito entra com analogia e exemplo.

Data: 2026-04-19

Como ler este guia

Este guia foi escrito para ensinar do zero. Não assume que você conhece nenhum dos termos técnicos usados no artigo. Cada conceito é apresentado em três passos:

1. **A ideia em linguagem cotidiana**, com uma analogia tirada do dia a dia.
2. **O nome técnico** que cientistas usam para essa ideia.
3. **Como isso aparece no estudo CorePAM** especificamente.

Quando um termo técnico é introduzido, ele é explicado no ato. Quando volta a aparecer, é sempre acompanhado de uma frase curta de lembrança. Não existe “volte à página tal para rever” neste guia — a informação necessária está sempre ali, ao lado.

Leia na ordem. Cada seção constrói a anterior. Se pular, algumas analogias perdem o contexto.

PARTE I — O PROBLEMA QUE O ESTUDO RESOLVE

1. Câncer de mama não é uma doença só

Quando alguém ouve “câncer de mama”, imagina um tumor único, um inimigo só. A realidade é diferente: sob o mesmo nome existem pelo menos cinco doenças biologicamente distintas, com causas moleculares diferentes, comportamento clínico diferente e resposta a tratamento diferente.

Analogia. Pense em “veículos” como categoria. Um caminhão, uma moto, uma bicicleta e um avião são todos veículos — transportam pessoas ou carga —, mas você não trataria o motor de uma moto da mesma forma que o motor de um avião. O mesmo vale para cânceres de mama.

Duas pacientes podem ter tumores que ao microscópio parecem semelhantes, mas por dentro são movidos por mecanismos moleculares completamente distintos.

Os cinco grandes grupos (chamados de **subtipos intrínsecos**, porque vêm de dentro da biologia do tumor, não de sua aparência):

1. **Luminal A** — tumor que ainda “se lembra” de ser uma célula mamária normal. Cresce devagar, responde bem ao bloqueio hormonal, prognóstico mais favorável.
2. **Luminal B** — parecido com o Luminal A, mas cresce mais rápido e responde menos ao bloqueio hormonal.
3. **Enriquecido em HER2** — dirigido por uma proteína chamada receptor HER2 (uma proteína que recebe sinais de crescimento). Agressivo sem tratamento específico, mas hoje tratável com remédios que bloqueiam especificamente o receptor HER2.
4. **Basal-símile** — parecido com células basais da mama (as células da camada de baixo, que produzem leite na amamentação). Geralmente agressivo, frequentemente sem alvo hormonal.
5. **Normal-símile** — um grupo pequeno, controverso, que parece se comportar como tecido mamário normal; alguns pesquisadores questionam se é um subtipo verdadeiro ou um artefato técnico.

A descoberta de que o câncer de mama tinha esses cinco grupos foi feita por um grupo de pesquisadores liderado por Charles Perou, em 2000. Eles analisaram a atividade de milhares de genes em tumores e perceberam que os tumores se agrupavam naturalmente em cinco padrões.

Genes, expressão e atividade — um aparte didático. Um gene é uma receita escrita no DNA. Cada célula do corpo carrega as mesmas receitas, mas usa apenas um subconjunto delas. Quando uma célula “lê” uma receita e produz a proteína correspondente, dizemos que ela está **expressando** aquele gene. A quantidade de leituras é a **expressão gênica**. Medir expressão gênica é como perguntar à célula “quais receitas você está usando agora, e o quanto?”.

Tumores diferentes expressam conjuntos diferentes de genes. É como visitar cinco padarias e anotar quais receitas cada uma está usando naquele dia: você consegue distinguir a padaria dos croissants da padaria dos pães doces mesmo sem olhar para os produtos finais.

2. O painel de 50 genes — a base sobre a qual CorePAM foi construído

Em 2009, um grupo liderado por Joel Parker refinou a descoberta dos subtipos. Em vez de medir milhares de genes (caro e ruidoso), eles selecionaram **50 genes específicos** que, juntos, classificavam corretamente os cinco subtipos e prediziam bem o prognóstico da paciente. Esse conjunto ficou conhecido pelo nome **PAM50** — uma sigla técnica que literalmente significa “Predictor Analysis of Microarray 50” (uma análise estatística que usa 50 marcadores). Para os fins deste guia, vamos chamá-lo simplesmente de **o painel de 50 genes**.

Analogia. Se o câncer de mama fosse um julgamento, o painel de 50 genes seria o conjunto de 50 perguntas-chave que um juiz experiente faria para decidir o caso. Com as 50 respostas, o juiz acerta quase sempre. Com menos perguntas, corre o risco de errar mais.

O Prosigna — o painel de 50 genes virou produto comercial

Em 2013, uma empresa chamada NanoString lançou um teste comercial chamado **Prosigna**, baseado exatamente nesses 50 genes. O teste roda em uma máquina específica (a NanoString nCounter), aprovada por agências regulatórias para uso clínico. Custa, em dólares, cerca de três mil e quinhentos dólares por amostra. Requer equipamento dedicado, reagentes proprietários e amostras preparadas de um jeito específico.

O Prosigna ajuda o oncologista a decidir, por exemplo, se uma paciente com câncer de mama hormônio-sensível (Luminal A ou B) precisa de quimioterapia além do bloqueio hormonal, ou se o bloqueio hormonal sozinho já é suficiente. Essa decisão afeta a vida de milhares de pacientes por ano.

O problema: acesso

Três mil e quinhentos dólares por amostra é um preço inviável para a maioria dos sistemas públicos de saúde, inclusive para o sistema único brasileiro. Plataformas como a NanoString nCounter raramente estão disponíveis fora de grandes centros. Isso cria uma desigualdade: pacientes em países ricos têm acesso a informação genômica que pacientes em países de média e baixa renda não têm — o que se traduz em decisões terapêuticas mais imprecisas para as segundas.

O cenário brasileiro, em 2024 e adiante

No Brasil, em 2024, a Comissão Nacional de Incorporação de Tecnologias no Sistema Único de Saúde (a comissão que decide quais exames e remédios o sistema público passa a cobrir) incorporou o teste de vinte e um genes mais conhecido do mundo — o que nos Estados Unidos é chamado *OncotypeDX* — apenas para um subgrupo clínico restrito. Os demais testes genômicos de câncer de mama (o teste de cinquenta genes chamado *Prosigna*, o teste de setenta genes chamado *MammaPrint* e o de doze genes chamado *EndoPredict*) continuam fora da cobertura pública. A consequência prática é que, mesmo em centros acadêmicos públicos brasileiros de ponta, a indicação de quimioterapia em câncer de mama com receptor de estrogênio positivo e sem HER2 continua apoiada majoritariamente em critérios clássicos — idade, tamanho do tumor, linfonodos acometidos, grau histológico, marcador de proliferação por imuno-histoquímica. Isso produz um número certo, ainda que hoje desconhecido, de pacientes tratadas a mais do que precisariam, ou a menos do que precisariam.

O estudo CorePAM nasce dessa desigualdade.

3. A ideia central — fazer mais com menos

A pergunta que o estudo CorePAM tenta responder é:

É possível usar menos genes e ainda prever o prognóstico da paciente tão bem quanto os 50 genes originais?

Se a resposta for “sim, com, digamos, vinte e tantos genes”, abre-se a porta para testes mais baratos, em plataformas mais comuns, que poderiam chegar a mais pacientes.

Analogia. Imagine um cardápio de cinquenta pratos em um restaurante. Se você descobrir que apenas vinte e quatro pratos respondem por noventa e nove por cento da receita e da satisfação dos clientes, pode reduzir o cardápio para vinte e quatro sem piorar o restaurante — e ainda baixa o custo de estoque, treinamento e logística. O nome técnico dessa ideia é **redução de dimensionalidade**: manter a essência informativa do conjunto grande usando um conjunto menor.

Mas a história tem um detalhe crucial. **Outros pesquisadores já tinham tentado** encolher o painel de 50 genes, sem sucesso convincente. Por quê?

1. **Escolhiam o número de genes antes de olhar os dados.** Diziam “vamos ficar com 20 genes” e então escolhiam os 20 melhores. O problema: talvez 20 seja demais (e haja redundância) ou de menos (e se perca informação crucial). O número deveria sair dos dados, não da intuição do pesquisador.
2. **Testavam cada gene sozinho.** Olhavam gene por gene, escolhiam os com maior associação isolada ao desfecho, e montavam um painel. Mas genes trabalham em grupos correlacionados — é como escolher um time de futebol olhando apenas estatísticas individuais, ignorando como os jogadores se completam.
3. **Misturavam plataformas tecnológicas sem cuidado.** Combinavam dados vindos de tecnologias diferentes (sequenciamento de nova geração, microarranjos de diversos fabricantes) como se fossem a mesma coisa. Mas cada plataforma tem vieses próprios. Misturar sem preprocessar independentemente é como comparar temperaturas medidas em Celsius e Fahrenheit sem converter.

O estudo CorePAM corrige esses três pontos. Vamos ver como.

PARTE II — ENTENDENDO OS MÉTODOS, UM POR UM, COM ANALOGIA

Esta parte é longa porque os métodos estatísticos são o coração do estudo. Cada subseção introduz um conceito com analogia, depois mostra como ele aparece no CorePAM.

4. O que é “prognóstico”?

Diagnóstico é descobrir o que a paciente tem agora. **Prognóstico** é prever o que vai acontecer com ela no futuro — vai viver quanto tempo, vai ter recidiva, vai responder ao tratamento.

Analogia. Um médico olha para o paciente e diz “você tem pneumonia” (diagnóstico). Depois diz “com antibiótico, em sete dias você estará bem” (prognóstico). Diagnóstico é fotografia; prognóstico é cinema.

No câncer de mama, o prognóstico é medido por perguntas como: - “Qual a chance de essa paciente estar viva em cinco anos?” - “Qual a chance de o tumor voltar em dez anos?” - “Se fizermos quimioterapia antes da cirurgia, o tumor vai sumir completamente?”

O estudo CorePAM foca nas duas primeiras perguntas (sobrevida e recidiva) como análise principal e na terceira pergunta (resposta à quimioterapia pré-cirurgia) como análise secundária.

5. Como se mede “capacidade de prever”? — a analogia do índice de concordância

Suponha que você tem um grupo de dez pacientes e quer avaliar se um escore prognóstico (um número que o modelo dá) realmente ordena bem o risco. Uma forma intuitiva:

Pegue todos os pares possíveis de pacientes. Para cada par, veja se a paciente que o modelo previu como “maior risco” de fato foi a que morreu primeiro. Conte a proporção de pares em que o modelo acertou essa ordem.

Se o modelo acerta 100% dos pares, ele é perfeito. Se acerta 50%, ele é igual a jogar moeda (chute aleatório). Números entre esses dois extremos medem o quanto o modelo é melhor que o acaso.

Essa proporção tem um nome técnico: **índice de concordância**. O próprio Frank Harrell propôs esse índice em 1982 e ele é o padrão-ouro para avaliar modelos prognósticos. No artigo do CorePAM, sempre que você vê “índice de concordância”, pense em **proporção de pares de pacientes que o modelo ordenou corretamente**.

Escala prática: - 0,50 = sorte pura, zero capacidade preditiva. - 0,60 = modestamente melhor que o acaso. - 0,70 = bom em oncologia (a maioria dos bons modelos prognósticos está aqui). - 0,80 = muito bom; raro em câncer de mama. - 0,90 ou mais = suspeito; provavelmente overfitting (modelo decorou os dados em vez de aprender).

O CorePAM atinge índices de concordância entre 0,62 e 0,70 nas coortes externas — patamar comparável ao Prosigna comercial.

6. O que é “razão de risco”? — a analogia do acelerador

Imagine dois carros idênticos em uma corrida, exceto que um deles tem um pedal extra que, quando pressionado um pouco mais, aumenta a velocidade do carro em uma fração fixa. A **razão de risco** é o equivalente desse pedal para o risco de um evento (morte, recidiva).

Como funciona. Se a razão de risco é 1,40 por unidade do escore CorePAM, significa: para cada aumento de uma unidade no escore, o risco da paciente sofrer o evento multiplica por 1,40 — ou seja, aumenta 40%. Se a razão de risco é 1,00, não há efeito (o pedal não faz nada). Se é menor que 1,00, o fator é protetor (apertar o pedal *reduz* o risco).

No estudo CorePAM, as razões de risco encontradas nas coortes externas variaram de 1,20 (efeito menor, mas ainda real) a 1,71 (efeito forte). Importante: todas foram maiores que 1. A direção é consistente em todas as coortes — quem tem escore alto morre mais cedo ou tem mais recidiva. Essa consistência é o achado mais sólido do estudo.

Uma unidade do escore — o que significa? O escore CorePAM é padronizado dentro de cada coorte de modo que ele tenha média zero e desvio padrão um. Em termos simples: “uma unidade” equivale a “um passo típico de variação entre pacientes dessa coorte”. Pacientes 1 passo acima da média são o que está sendo comparado contra pacientes na média.

7. Validação cruzada — a analogia da prova que nunca foi estudada

Você está estudando para uma prova. Se você fizer a prova que já viu durante os estudos, vai tirar uma nota alta — mas isso não mede se você aprendeu, só mede se você decorou aquelas questões específicas. Para medir aprendizado, precisa de uma **prova nova**, que você nunca viu.

Em modelos estatísticos, o mesmo princípio se aplica. Se eu treino o modelo com todos os dados e avalio o desempenho nos mesmos dados, ele parecerá sempre ótimo — mas isso não garante que funcione em pacientes novos. A técnica para simular “prova nova” usando os próprios dados chama-se **validação cruzada**.

Como funciona a validação cruzada em dez partes (o esquema usado no CorePAM):

1. Divida os 3.069 pacientes da coorte de derivação em dez grupos de ~307 pacientes cada. Esses grupos se chamam **folds** (palavra em inglês; em português, “dobras”, mas vamos usar “fold” porque é como aparece na literatura).
2. Treine o modelo usando nove desses grupos (2.762 pacientes) e teste no grupo restante (307 pacientes). O modelo nunca viu esse grupo durante o treino — é uma “prova nova”.
3. Repita o processo dez vezes, cada vez deixando um grupo diferente de fora.
4. Combine os dez resultados. Isso dá uma estimativa honesta do desempenho do modelo em dados não vistos.

O índice de concordância calculado desse jeito é chamado de **índice de concordância fora da amostra** (em inglês, “out-of-fold”). No CorePAM, esse número é **0,670** — a estimativa honesta de quão bem o modelo de 24 genes ordena pacientes que ele nunca viu.

Hash determinístico — um aparte técnico importante

Um detalhe que parece chato mas é central para reprodutibilidade: **como você decide qual paciente vai para qual dos dez grupos?**

A resposta comum seria “sorteio aleatório”. O problema: diferentes pesquisadores, usando sementes aleatórias diferentes, montam grupos diferentes — e então chegam a painéis de genes diferentes. Se o resultado do estudo depende da semente aleatória usada, ele não é verdadeiramente reprodutível.

O CorePAM resolve isso com uma **função de resumo criptográfico** — um cálculo matemático que transforma o número de identificação de cada paciente em um código fixo. Usou-se a função

chamada SHA-256 (uma função de resumo muito usada em segurança digital, a mesma que protege senhas de sites). O código fixo gerado é sempre o mesmo para o mesmo número de paciente, em qualquer computador, em qualquer dia. Esse código decide em qual grupo o paciente cai.

Analogia. Em vez de tirar papezinhos de uma caixa, você dá a cada paciente um carimbo com a primeira letra do nome. Pacientes com carimbo A vão para o grupo 1, com B para o grupo 2, e assim por diante. Qualquer pessoa que pegar os mesmos nomes vai montar exatamente os mesmos grupos. Zero aleatoriedade, zero dependência de semente. Reprodutibilidade total.

8. Regularização — a analogia de escolher colegas para um projeto

Você precisa montar uma equipe de trabalho usando colegas de um grupo de 50 candidatos. Duas abordagens ingênuas falham:

1. **Pegar todos os 50:** a equipe fica grande demais, cara, lenta, com muita redundância (vários colegas sabem a mesma coisa).
2. **Pegar só os 3 melhores:** a equipe fica pequena demais, sem cobertura de áreas importantes.

A solução inteligente é **penalizar o tamanho da equipe**: para cada colega adicional, você paga um custo fixo. Esse custo força você a escolher apenas os colegas cuja contribuição única supera o custo. Colegas redundantes são naturalmente filtrados.

Esse mecanismo, em estatística, se chama **regularização**. Existem dois tipos principais:

Regularização por tipo “raiz quadrada do tamanho” (conhecida tecnicamente como L2, ou Ridge): penaliza pesos grandes, mas nunca zera nenhum. Resultado: mantém todos os genes, só dilui o peso dos menos importantes. Útil quando muitos genes contribuem um pouquinho cada.

Regularização por tipo “valor absoluto” (conhecida tecnicamente como L1, ou LASSO — sigla que significa “operador de seleção e encolhimento por mínimos valores absolutos”): penaliza pesos grandes e, ao contrário da Ridge, pode zerar pesos completamente. Isso significa que ela **seleciona** quais genes ficam no modelo e quais saem.

Elastic-net — o equilíbrio entre os dois

O CorePAM usa uma técnica chamada **elastic-net** (rede elástica), que é uma mistura dos dois tipos de regularização. Ela combina a propriedade de selecionar genes (herdada do LASSO) com a propriedade de distribuir peso entre genes correlacionados (herdada do Ridge).

Por que essa combinação importa. Genes biológicos trabalham em grupos correlacionados. Os genes de proliferação celular, por exemplo, tendem a ser expressos juntos: se um tumor está crescendo depressa, uma dúzia de genes associados à divisão celular se ativam em bloco. Se você usa LASSO puro, ele escolhe um desses genes de proliferação (meio arbitrariamente) e ignora os outros. Isso é instável: um pequeno tremor nos dados pode fazer o LASSO escolher um gene diferente do grupo, o que dá a impressão de resultados que não se repetem.

O elastic-net distribui o peso entre os genes correlacionados. Se três genes de proliferação contribuem de forma parecida, o elastic-net dá peso para todos os três, de forma proporcional. Resultado: o modelo é mais estável quando você refaz a análise com uma amostra ligeiramente diferente de pacientes.

O parâmetro alfa. O equilíbrio entre os dois tipos é controlado por um número chamado alfa. Alfa igual a zero é Ridge puro. Alfa igual a um é LASSO puro. Alfa igual a 0,5 é meio a meio. O CorePAM usa alfa igual a 0,5 — decisão pré-especificada antes de olhar os dados.

O parâmetro lambda. A “força” da regularização (quanto custa, em números, cada gene adicional na equipe) é controlada por outro número, chamado lambda. Lambda pequeno = custo baixo = muitos genes entram no modelo. Lambda grande = custo alto = poucos genes entram. No CorePAM, o modelo é treinado com muitos valores diferentes de lambda, e o número de genes selecionados varia de 0 a 50 conforme lambda varia do altíssimo para o baixíssimo.

9. A fronteira de Pareto — como escolher a equipe ótima

Imagine que você treinou o modelo com muitos valores de lambda diferentes. Para cada valor, você tem um par de números:

- **Número de genes selecionados** (varia de 1 a 50 conforme lambda cai).
- **Índice de concordância fora da amostra** (o tal “0,670” que aparece no artigo).

Você pode plotar esses pares em um gráfico: no eixo horizontal, número de genes; no eixo vertical, índice de concordância. O que aparece é uma curva que cresce rapidamente no começo (cada gene novo adiciona muita informação), desacelera, e eventualmente estabiliza (adicionar mais genes não melhora).

Analogia. Imagine que você está comprando sacos de farinha para um bolo. O primeiro saco é essencial. O segundo ainda faz diferença. O terceiro já ajuda pouco. Do quarto em diante, você está só enchendo o armário. Em algum ponto, comprar mais farinha é desperdício.

Esse padrão de retorno decrescente tem um nome em economia: **fronteira de Pareto** (em homenagem ao economista Vilfredo Pareto). No CorePAM, o ponto escolhido é o menor número de genes para o qual o índice de concordância está dentro de uma margem pré-definida do máximo.

A margem pré-definida — o número 0,010. Os autores decidiram, *antes de olhar os dados*, que uma perda de 0,010 no índice de concordância seria considerada negligível. Por que 0,010? Porque esse número é menor que metade da incerteza estatística (erro padrão) do próprio índice de concordância. Em termos simples: 0,010 é menor que a margem de erro da medida — então uma diferença dessa magnitude é estatisticamente indistinguível de ruído.

Com essa margem de 0,010, o ponto ótimo da fronteira de Pareto caiu em **24 genes**. O índice de concordância com 24 genes é 0,670. O máximo (com todos os 50 genes) é 0,679. A diferença é 0,009 — dentro da margem de 0,010.

Ponto filosófico crucial. O número 24 **não foi escolhido pelos autores**. Ele emergiu dos dados, dada a regra pré-especificada. Se a margem fosse 0,005 (mais rigorosa), o resultado seria 31 genes. Se fosse 0,020 (mais relaxada), seria 16 genes. Os autores mostram essa análise de sensibilidade para deixar claro que a regra é robusta — o resultado não desaparece com uma margem ligeiramente diferente.

10. Não-inferioridade — a analogia do remédio genérico

Quando um laboratório lança um remédio genérico, ele não precisa provar que é **melhor** que o original. Precisa provar que é **não pior o suficiente para importar**. Essa é a lógica da **não-inferioridade**.

Analogia. Imagine que o remédio original cura 85% dos pacientes em 7 dias. O genérico precisa curar pelo menos... 83%? 80%? Esse número — a **margem de não-inferioridade** — é escolhido pelos pesquisadores antes do estudo, com base no que faria diferença clínica. Se o genérico cura 84%, a diferença é clinicamente irrelevante (não-inferior). Se cura 70%, é inferior demais.

No CorePAM, a ideia é a mesma, mas aplicada a modelos estatísticos:

O modelo com 24 genes é “não pior o suficiente para importar” comparado ao modelo com 50 genes, dentro da margem de 0,010 no índice de concordância.

Essa é a **alegação central** do artigo. Não é “CorePAM é melhor que o PAM50”. Não é “CorePAM substitui o Prosigna”. É, literalmente, “você pode usar 24 genes no lugar de 50 com perda estatisticamente negligível”.

Importante: a comparação é feita dentro do mesmo esquema estatístico (elastic-net com 50 candidatos vs elastic-net com 24 genes selecionados), **não** contra o Prosigna comercial. O Prosigna é outro produto, com outro algoritmo interno (classificação em subtipos + escore de risco ponderado), rodando em outra plataforma. Comparar CorePAM com Prosigna diretamente exigiria outro estudo.

11. Padronização (z-score) — a analogia da altura da turma

Você quer comparar a altura do seu filho de 8 anos com a de um amigo da mesma idade. Altura bruta (em centímetros) já funciona, mas é mais informativo perguntar: **quantos desvios padrão acima ou abaixo da média de crianças de 8 anos ele está?**

Se seu filho mede 130 cm, e a média de meninos de 8 anos é 125 cm com desvio padrão de 5 cm, então seu filho está 1 desvio padrão acima da média. Essa conversão de “centímetros” para “desvios padrão” chama-se **padronização** ou **z-score**.

Fórmula em palavras: pegue o valor bruto, subtraia a média do grupo, divida pelo desvio padrão do grupo. O resultado é um número que diz “quantos desvios padrão acima (positivo) ou abaixo (negativo) da média”.

No CorePAM, cada gene é padronizado dentro de cada coorte. Isso coloca todos os genes na mesma escala (desvio padrão 1), independentemente de se expressar pouco ou muito em termos absolutos. O escore do CorePAM é a soma ponderada desses valores padronizados:

$$\text{escore da paciente} = (\text{peso do gene 1}) \times (\text{z-score do gene 1 na paciente}) + (\text{peso do gene 2}) \times (\text{z-score do gene 2 na paciente}) + \dots + (\text{peso do gene 24}) \times (\text{z-score do gene 24 na paciente})$$

Divide-se por uma constante (a soma dos valores absolutos dos pesos) para garantir que o escore fique na mesma escala mesmo se algum gene estiver faltando na coorte.

O problema do z-score “da coorte” — e a solução “congelada”

A padronização z-score exige conhecer a **média** e o **desvio padrão** do grupo inteiro. Em um estudo de validação com 1.000 pacientes, isso funciona: você calcula média e desvio dos 1.000.

Mas **na clínica real, você tem uma paciente por vez**. Ela chega no consultório, você quer calcular o escore dela, mas você só tem uma amostra. Qual é a média? Qual é o desvio padrão?

A solução do CorePAM:

1. Calcule média e desvio padrão de cada gene na coorte de derivação (a sueca, com 3.069 pacientes).
2. **Congele** esses valores — eles passam a ser constantes conhecidas.
3. Para qualquer paciente futura, normalize os valores de expressão dela usando essas constantes congeladas.

Esse esquema chama-se **z-score congelado**. Ele simula o cenário clínico real.

Teste do esquema: Os autores aplicaram o z-score congelado nas quatro coortes de validação e compararam o desempenho com o z-score intra-coorte (onde usa-se a média e o desvio da própria coorte de validação). O resultado:

- Em coorte de sequenciamento de nova geração (tecnologia semelhante à de derivação): perda de desempenho praticamente zero — o z-score congelado funciona muito bem.
- Em coorte de microarranjo do fabricante Illumina (tecnologia parecida): perda mínima.
- Em coortes de microarranjo do fabricante Affymetrix (tecnologia diferente): perda maior (índice de concordância cai cerca de 0,04 pontos).

Conclusão honesta dos autores: o esquema congelado é **dependente de plataforma**. Funciona excelente em sequenciamento e em microarranjo Illumina; precisa de recalibração específica em plataformas Affymetrix. Essa limitação está explicitamente declarada no artigo.

12. Ensaios clínicos e parâmetros congelados — por que importa?

Quando uma farmacêutica roda um ensaio clínico de um novo remédio, ela precisa **pré-registrar** o protocolo inteiro: qual a dose, qual o desfecho principal, quanto tempo de seguimento, qual a margem de não-inferioridade, e assim por diante. Esse pré-registro é publicado e serve como

compromisso: depois que os dados são coletados, os pesquisadores não podem mudar as regras do jogo.

Por que importa? Porque sem pré-registro, é fácil pescar resultados. Você roda 20 análises diferentes, encontra uma que deu positiva por acaso, e reporta só essa. O leitor fica com a impressão de que o achado é sólido, quando na verdade é ruído selecionado a posteriori. Esse problema tem um nome: **pescaria de dados** (em inglês, “data dredging” ou “p-hacking”).

No CorePAM, os autores aplicaram a mesma disciplina. **Antes** de rodar qualquer análise, eles congelaram:

- A margem de não-inferioridade: 0,010.
- O parâmetro alfa do elastic-net: 0,5.
- Número de folds da validação cruzada: 10.
- Como decidir o fold de cada paciente: função de resumo criptográfico SHA-256.
- Cobertura mínima de genes por coorte: 80%.
- Unidade de tempo: meses.
- **Não** pré-especificaram o número final de genes — esse tinha que sair dos dados, via fronteira de Pareto.

Esses parâmetros congelados foram documentados em um arquivo público, colocado em um repositório online (o GitHub). Qualquer pessoa pode verificar que as decisões foram tomadas antes da análise final.

Analogia. É como colocar as regras do jogo em um cofre à prova de manipulação antes de começar a partida. Se depois alguém quiser mudar as regras para fazer seu time parecer melhor, não consegue — o cofre denuncia.

PARTE III — ENTENDENDO OS DADOS

13. As coortes — um tour pelos grupos de pacientes

Um **coorte** em estudos clínicos é simplesmente um grupo de pacientes acompanhados ao longo do tempo. No CorePAM, foram usadas cinco coortes principais para prognóstico (sobrevida e recidiva) e mais quatro para a análise secundária (resposta à quimioterapia pré-cirurgia). Vamos conhecer cada uma.

A coorte de derivação — 3.069 pacientes suecas

Nome do grupo: Sweden Cancerome Analysis Network — Breast, identificado na literatura pela sigla SCAN-B. Vamos chamar de **a coorte sueca**. **Número de pacientes:** 3.069. **Origem:** Suécia, projeto nacional de sequenciamento de cânceres de mama. **Tecnologia usada:** sequenciamento de nova geração de RNA (processo em que o conteúdo de RNA da amostra é lido por máquinas de sequenciamento e transformado em contagens de cada gene). **Tempo de**

seguimento: cerca de 4,5 anos em média. **Eventos observados:** 322 mortes por qualquer causa durante o seguimento. **Referência acadêmica:** Brueffer e colaboradores, 2018.

Importância. Esta é a **maior coorte pública** de câncer de mama com sequenciamento de RNA e seguimento clínico. É o conjunto ideal para derivar o modelo: grande o suficiente para dividir em dez folds de validação cruzada e ainda ter poder estatístico em cada um.

A coorte americana — 1.072 pacientes

Nome do grupo: The Cancer Genome Atlas — BReast invasive CArcinoma. A sigla usada é TCGA-BRCA. Vamos chamar de **a coorte americana**. **Número de pacientes:** 1.072. **Origem:** rede multicêntrica estadunidense de sequenciamento de cânceres. **Tecnologia usada:** sequenciamento de nova geração de RNA. **Tempo de seguimento:** cerca de 2,7 anos em média — **curto** para câncer de mama (muitas pacientes ainda estavam no começo do seguimento quando o dado foi congelado). **Eventos observados:** 150 mortes. **Cobertura de genes do CorePAM:** 23 dos 24 genes (falta um gene chamado MIA, que codifica uma proteína relacionada à diferenciação celular).

Particularidade importante. O status do receptor de estrogênio (aquela informação clínica crucial para decidir tratamento hormonal) **não está disponível** na versão pública harmonizada dos dados americanos. Por isso, no CorePAM, a coorte americana é analisada apenas com idade como covariável (sem ajuste por receptor de estrogênio).

A coorte britânica/canadense — 1.978 pacientes

Nome do grupo: Molecular Taxonomy of Breast Cancer International Consortium. A sigla é METABRIC. Vamos chamar de **a coorte britânica** (embora tenha envolvido pesquisadores canadenses também). **Número de pacientes:** 1.978. **Origem:** Reino Unido e Canadá. **Tecnologia usada:** microarranjo Illumina modelo HT-12 (uma tecnologia mais antiga, em que a expressão de genes é medida por hibridização em chips). **Tempo de seguimento:** cerca de 13 anos em média — **muito longo**. **Desfecho principal:** sobrevida específica por câncer (mortes por câncer são contadas; mortes por outras causas são “censuradas”, ou seja, o paciente sai do estudo vivo em relação ao câncer). **Eventos observados:** 646 mortes atribuídas ao câncer. **Referência:** Curtis e colaboradores, 2012.

Por que sobrevida específica e não sobrevida global? Com 13 anos de seguimento, muitas pacientes morreram de outras coisas (infarto, acidente, outras doenças). Para medir o efeito do CorePAM sobre a evolução do câncer propriamente dito, faz mais sentido contar só as mortes por câncer. Essa é a prática padrão nessa coorte desde a publicação original.

A coorte taiwanesa — 327 pacientes

Identificação técnica: o conjunto de dados tem o código GSE20685 no repositório público de dados genômicos. Vamos chamar de **a coorte taiwanesa** porque foi coletada em Taiwan. **Número de pacientes:** 327. **Tecnologia:** microarranjo Affymetrix modelo HG-U133 Plus 2.0. **Tempo de seguimento:** cerca de 7,6 anos em média. **Eventos observados:** 83 mortes. **Cobertura de genes do CorePAM:** 24 dos 24 (completa).

Nota histórica. Em uma versão inicial do estudo, foi usada uma anotação errada dessa coorte (anotação de outro modelo de chip). O erro foi detectado e corrigido antes da submissão. A cobertura passou de 22/24 (errada) para 24/24 (correta). Essa correção está documentada no histórico do projeto.

A coorte de Estocolmo — 159 pacientes

Identificação: conjunto GSE1456 no repositório público, coletado no Hospital Karolinska, em Estocolmo. Vamos chamar de **a coorte de Estocolmo** (para não confundir com a coorte sueca maior, também da Suécia). **Número de pacientes:** 159. **Tecnologia:** microarranjo Affymetrix modelo HG-U133A/B (uma versão anterior à da coorte taiwanesa). **Eventos observados:** 40 mortes. **Cobertura de genes do CorePAM:** 21 dos 24 (faltam três genes: GPR160, CXXC5 e KRT17). **Particularidade:** sem informações clínicas de idade ou receptor de estrogênio. Por isso, nesta coorte, só é possível fazer análise não-ajustada (sem covariáveis clínicas).

Por que cinco coortes, e não só uma?

Uma única coorte poderia dar resultado por acaso ou por alguma peculiaridade local (viés de seleção, tecnologia específica, características populacionais). Quando o mesmo resultado aparece em cinco coortes diferentes — três continentes, três décadas, quatro tecnologias — a força da evidência cresce muito.

Analogia. Se um amigo seu diz que determinado restaurante é ótimo, talvez seja gosto dele. Se cinco amigos independentes, de contextos diferentes, dizem o mesmo, a coisa vira recomendação sólida. O mesmo raciocínio em estatística: **consistência através de contextos independentes** é uma das formas mais fortes de evidência.

As coortes de quimioterapia pré-cirurgia — análise secundária

Para avaliar se o escore CorePAM prevê quem vai responder à quimioterapia feita antes da cirurgia (chamada quimioterapia neoadjuvante), foram usadas quatro coortes menores, totalizando 697 pacientes:

- **Coorte de Houston** (código GSE25066): 182 pacientes, maior das quatro.
- **Coorte do consórcio de qualidade de microarranjo** (código GSE20194): 278 pacientes.
- **Coorte japonesa** (código GSE32646): 115 pacientes.
- **Coorte de São Francisco inicial** (código GSE22226): 122 pacientes, estudo conhecido como I-SPY 1.

O desfecho observado nessas coortes é a **resposta patológica completa** — quando a paciente faz quimioterapia antes da cirurgia, e ao operar, o patologista encontra zero células tumorais residuais. É um desfecho binário (sim ou não) e serve como marcador precoce de bom prognóstico.

Adicionalmente, uma coorte exploratória chamada **I-SPY 2** (código GSE194040, 986 pacientes) foi analisada como confirmação independente.

14. Entendendo as tecnologias — sequenciamento vs microarranjo

Você viu nas descrições das coortes duas palavras técnicas repetidas: **sequenciamento de nova geração** e **microarranjo**. Vamos entender o que são e por que a diferença importa.

Sequenciamento de nova geração de RNA. Imagine que você quer saber quantos exemplares de cada receita (gene) estão sendo usados na cozinha do tumor. O sequenciamento despeja todo o conteúdo de RNA da amostra em uma máquina que lê, letra a letra, cada molécula de RNA e depois conta quantas vezes cada receita aparece. Tecnologia moderna (principalmente a partir de 2008), detalhada, sensível a níveis baixos de expressão.

Microarranjo. Pense em um chip de vidro com milhares de pequenas “iscas” — cada isca é uma sequência de DNA que se liga apenas a um gene específico. Você despeja o RNA da amostra sobre o chip, e cada molécula de RNA se “gruda” na isca correspondente. Então você mede quanto se grudou em cada posição do chip, usando fluorescência. Tecnologia mais antiga (dominante de 2000 a 2012, aproximadamente), mais barata, mas menos sensível a genes com baixa expressão e com limite dinâmico menor.

Por que a diferença importa no CorePAM? Porque o modelo foi derivado em uma coorte de sequenciamento (a sueca) e precisa funcionar em coortes de microarranjo (britânica, taiwanesa, de Estocolmo). As duas tecnologias medem a mesma coisa (expressão gênica) mas em escalas ligeiramente diferentes. Se o modelo “aprendeu” características específicas do sequenciamento, ele pode não funcionar em microarranjo. O fato de o CorePAM funcionar nas duas tecnologias (com a ressalva de recalibração em Affymetrix) é parte da demonstração de robustez.

PARTE IV — OS RESULTADOS E O QUE SIGNIFICAM

15. O resultado principal da derivação

Lembre da fronteira de Pareto (Parte II, seção 9). Ela respondeu à pergunta “quantos genes?”:

- **Número de genes selecionados:** 24.
- **Índice de concordância fora da amostra com 24 genes:** 0,670.
- **Índice de concordância fora da amostra com todos os 50 genes:** 0,679.
- **Diferença:** 0,009, abaixo da margem pré-especificada de 0,010.

Interpretação em linguagem cotidiana: o modelo de 24 genes ordena pacientes por risco praticamente tão bem quanto o modelo de 50 genes, em uma coorte de mais de três mil pacientes.

Análise de sensibilidade da margem

Os autores refizeram o cálculo com margens diferentes para ver se o resultado é robusto:

Margem usada	Número de genes selecionados
0,005 (mais rigorosa)	31 genes
0,010 (a escolhida)	24 genes
0,015 (mais relaxada)	18 genes
0,020 (muito relaxada)	16 genes

Não há um salto abrupto. O número de genes varia suavemente conforme a margem. Isso indica que a escolha da margem não é “brittle” (quebradiça): pequenas mudanças de margem levam a pequenas mudanças no número de genes. A conclusão geral (é possível reduzir substancialmente o painel) se mantém em todas as margens razoáveis.

16. A comparação direta 24 versus 49 genes

Uma análise adicional, incluída na segunda revisão do artigo: comparar diretamente o modelo de 24 genes (CorePAM) contra o modelo do elastic-net com 49 genes não-zero (o máximo antes de o lambda forçar alguma zeragem).

Resultado surpreendente. O modelo de 24 genes **superou** o modelo de 49 genes em três das quatro coortes externas:

Coorte	Diferença (24 menos 49 genes)	Veredito
Americana	−0,008	Equivalente
Britânica	+0,022	24 genes superior
Taiwanesa	+0,055	24 genes superior
Estocolmo	+0,097	24 genes superior

Interpretação intuitiva. Por que o modelo menor superou o maior em três de quatro coortes externas? Porque modelos com menos genes generalizam melhor para dados novos — eles captam a essência biológica do problema e menos do ruído específico da coorte de treino.

Analogia. Um estudante que decorou 1.000 páginas de anotações específicas da turma dele vai se sair pior em uma prova feita por outro professor do que um estudante que entendeu os 24 conceitos fundamentais. O primeiro memorizou; o segundo aprendeu. Em estatística, esse fenômeno é o chamado **sobreajuste** (em inglês, *overfitting*) — quando o modelo decora os dados de treino em vez de aprender os padrões gerais. Reduzir o número de parâmetros (via regularização) é uma das formas de combater o sobreajuste.

16B. Comparação com testes comerciais estabelecidos

A comparação do modelo de vinte e quatro genes contra o modelo de quarenta e nove genes é uma comparação **interna** (os dois modelos nascem do mesmo procedimento, a única diferença

sendo quantos genes cada um usa). Mas resta uma pergunta externa, mais severa: como o CorePAM se sai contra os testes comerciais já consolidados na clínica?

Os autores compararam o CorePAM contra duas assinaturas de referência:

1. A componente de subtipo do teste de cinquenta genes comercial — conhecida pela sigla *ROR-S* (do inglês *risk of recurrence, subtype-based*, que significa literalmente “risco de recorrência baseado no subtipo”). É a forma pela qual o teste comercial entrega o prognóstico numérico ao oncologista.
2. O escore de recorrência do teste de vinte e um genes — conhecido como *escore de recorrência* (em inglês, *Recurrence Score*), padrão-ouro na clínica americana para pacientes com câncer de mama hormônio-positivo e linfonodos negativos.

As duas foram calculadas nas mesmas coortes, pela mesma biblioteca de software (chamada *genefu*, um pacote de código aberto que implementa essas fórmulas de forma reproduzível), garantindo comparação justa. O resultado revela um padrão plataforma-dependente que merece atenção cuidadosa.

Coorte	Tecnologia	CorePAM	Teste de 50 genes (ROR-S)	Teste de 21 genes
Sueca	Sequenciamento	0,698	0,641	0,607
Americana	Sequenciamento	0,624	0,602	0,586
Britânica	Microarranjo	0,638	0,643	0,665
Taiwanesa	Microarranjo	0,626	0,646	0,651

Os números mostram o índice de concordância — o quanto cada escore acerta, de zero e meio (acaso puro) a um (perfeito). O valor em negrito em cada linha é o melhor naquela coorte.

O que essa tabela está dizendo

Duas observações imediatas:

1. **Nas coortes de sequenciamento (sueca e americana), o CorePAM ganha dos dois competidores.** Não é ganho pequeno: na sueca, o CorePAM supera o teste de cinquenta genes por quase seis pontos percentuais de concordância e supera o teste de vinte e um genes por nove pontos. Na americana, cerca de dois e quatro pontos respectivamente.
2. **Nas coortes de microarranjo (britânica e taiwanesa), a ordem se inverte.** O teste de vinte e um genes passa a ser o melhor, o teste de cinquenta segundo, e o CorePAM terceiro — por margens pequenas (dois a três pontos).

Por que essa inversão é esperada, não um problema

Cada assinatura carrega a marca da tecnologia em que foi treinada. O CorePAM foi treinado em dados de sequenciamento da coorte sueca. O teste de cinquenta genes foi desenvolvido majoritariamente em microarranjos da época. O teste de vinte e um genes foi construído para uma plataforma específica de reação em cadeia da polimerase quantitativa, que compartilha propriedades estatísticas com microarranjos mais do que com sequenciamento. **Nenhuma ferramenta é universalmente ótima** em todas as tecnologias.

Analogia. Três corredores: um atleta de fundo acostumado a asfalto, um atleta de montanha acostumado a trilhas, um atleta de pista acostumado a oval. Em asfalto, o primeiro ganha. Em trilha, o segundo. Em pista, o terceiro. Nenhum é universalmente melhor — cada um domina seu terreno. A pergunta honesta não é “quem é o melhor no mundo?” mas “quem é o melhor nas condições em que eu vou usá-lo?”.

A leitura correta do resultado

O CorePAM foi o **único dos três** derivado com foco explícito em parcimônia (poucos genes) e em estabilidade entre tecnologias. Apesar disso, em nenhuma coorte foi o pior simultaneamente — sempre derrotou pelo menos um dos dois concorrentes. Em duas das quatro coortes, foi o melhor. Isso é competitividade real, não dominância universal — uma distinção honesta que o artigo faz questão de manter.

Moral prática. Se o destino clínico é sequenciamento (a tecnologia que vem crescendo em laboratórios acadêmicos brasileiros), o CorePAM é provavelmente a melhor escolha entre as três. Se o destino é microarranjo antigo, o teste de vinte e um genes ainda leva vantagem — mas microarranjo é tecnologia em fim de vida. O CorePAM aposta no futuro.

17. A tabela dos resultados de sobrevida — linha por linha

A tabela principal do artigo mostra o desempenho prognóstico em cada coorte. Vamos ler cada linha com cuidado.

Coorte	Pacientes	Eventos	Razão bruta	Razão ajustada	Concordância
Sueca	3.069	322	1,92	1,86	0,698
Americana	1.072	150	1,20	1,27	0,624
Britânica	1.978	646	1,41	1,36	0,638
Taiwanesa	327	83	1,40	1,40	0,626
Estocolmo	159	40	1,71	—	0,661

Intervalos de confiança de 95% para a razão bruta: Sueca 1,74–2,13; Americana 1,04–1,40; Britânica 1,31–1,52; Taiwanesa 1,12–1,75; Estocolmo 1,23–2,38.

Como ler esta tabela

Tome a linha da coorte britânica como exemplo:

- **Tamanho:** 1.978 pacientes foram analisadas.
- **Eventos:** 646 morreram de câncer durante o seguimento de 13 anos.
- **Razão de risco não-ajustada = 1,41:** para cada aumento de 1 unidade no escore CorePAM (uma unidade de desvio padrão, aproximadamente), o risco de morrer de câncer se multiplica por 1,41 — um aumento de 41%.

- **Intervalo de confiança 1,31 a 1,52:** a medida tem incerteza. A melhor estimativa é 1,41, mas o valor verdadeiro está, com 95% de probabilidade, entre 1,31 e 1,52. Note que este intervalo não inclui 1,00 — então o efeito é estatisticamente significativo.
- **Razão de risco ajustada = 1,36:** depois de levar em conta idade e status hormonal, o efeito do CorePAM por si só é 1,36. Ligeiramente menor que o bruto, mas ainda bastante maior que 1.
- **Índice de concordância = 0,638:** o modelo ordena corretamente pares de pacientes em 63,8% das vezes — modesto mas real.

Por que a razão de risco na coorte americana é a menor (1,20)?

A coorte americana tem o menor valor de razão de risco entre as externas. Por quê? Porque o seguimento médio é de apenas 2,7 anos. Em câncer de mama, a maioria das mortes acontece entre 3 e 15 anos após o diagnóstico. Com seguimento curto, muitas pacientes ainda não tiveram tempo de apresentar o evento, o que “dilui” o sinal prognóstico.

Evidência da diluição: uma análise de sensibilidade olhando apenas os primeiros 24 meses (janela mais “igualitária” entre quem morreu e quem ainda não morreu) mostrou razão de risco de 1,64, com significância estatística clara. Ou seja, o sinal está lá — apenas atenuado pelo seguimento curto da coorte americana. Isso é um artefato esperado, não uma falha do modelo.

Por que a coorte de Estocolmo não tem razão de risco ajustada?

Porque, lembre, a coorte de Estocolmo não tem dados clínicos de idade nem de receptor de estrogênio. Sem covariáveis, não há como ajustar. Só a análise não-ajustada é possível.

18. Meta-análise — unindo evidências

Quando você tem quatro coortes externas com resultados parecidos, mas não idênticos, é útil combinar todos em um único número-resumo. Essa combinação chama-se **meta-análise**.

Analogia. Quatro amigos dizem que um restaurante é bom. Um dá nota 8, outro 7, outro 9, outro 7,5. Em vez de listar as quatro notas, você tira uma média ponderada (dando mais peso aos amigos cujas notas são mais consistentes), chegando a um único número que resume todas as opiniões.

No CorePAM:

- **Razão de risco poolada (combinada) pela principal meta-análise:** 1,37.
- **Intervalo de confiança:** 1,24 a 1,52.
- **Valor-p:** $1,6 \times 10^{-9}$ (um número extremamente pequeno, evidência muito forte de que o efeito não é por acaso).
- **Medida de heterogeneidade, chamada I-quadrado:** 38,2%.

O que é o I-quadrado?

O **I-quadrado** mede o quanto as quatro coortes são heterogêneas entre si — ou seja, o quanto os resultados delas diferem além do esperado por acaso. Escala:

- I-quadrado abaixo de 25%: coortes muito consistentes.
- Entre 25% e 75%: consistência moderada.
- Acima de 75%: coortes divergem demais para simples combinação.

Analogia. Se os quatro amigos deram notas 7,5 — 8 — 7,8 — 7,7, o I-quadrado é baixo (todos concordam). Se deram 5 — 9 — 3 — 10, o I-quadrado é alto (opiniões divergem muito).

No CorePAM, 38,2% é heterogeneidade moderada. Mas os autores vão além e identificam **de onde** ela vem: principalmente do fato de a coorte britânica usar sobrevida específica por câncer (como desfecho), enquanto as outras usam sobrevida global. Quando os autores refazem a meta-análise usando sobrevida global na britânica também (análise de sensibilidade), o I-quadrado muda — confirmando que a heterogeneidade tem origem estrutural identificável, não aleatória.

O ponto crucial do artigo: a direção do efeito é consistente em 4 de 4 coortes (todas as razões de risco são maiores que 1). Mesmo com heterogeneidade moderada na magnitude, a direção não gera dúvida. Esse é o achado mais robusto.

19. Valor incremental — o escore adiciona algo além da clínica?

Um crítico justo pergunta: “*Tudo bem, o escore CorePAM se associa com o prognóstico. Mas idade e status hormonal também se associam. O escore adiciona alguma coisa além do que eu já consigo saber olhando só para a idade e o receptor de estrogênio?*”

Essa é a pergunta do **valor incremental**. Para responder, os autores definiram um modelo clínico mínimo de referência, chamado **modelo clínico basal** (por conveniência, vamos chamar de “modelo basal”). Ele inclui:

- **Idade** (em todas as coortes).
- **Receptor de estrogênio**, quando disponível (sim/não).

Então compararam o desempenho do modelo basal sozinho contra o modelo basal + escore CorePAM. O ganho no índice de concordância ao adicionar o escore é o **valor incremental**:

Coorte	Modelo basal	Modelo basal + CorePAM	Valor incremental
Sueca	idade + receptor de estrogênio	+ CorePAM	+0,030
Americana	apenas idade	+ CorePAM	+0,038
Britânica	idade + receptor de estrogênio	+ CorePAM	+0,043
Taiwanesa	apenas idade	+ CorePAM	+0,094

Interpretação: o escore CorePAM adiciona informação prognóstica mesmo depois de a idade e o receptor de estrogênio estarem no modelo. O valor incremental varia de 0,030 a 0,094 — mais notável na coorte taiwanesa, onde apenas a idade estava disponível (e portanto o modelo basal era mais fraco, deixando mais espaço para o escore agregar).

Independência do estadiamento

Uma pergunta ainda mais rigorosa: *e se eu adicionar, além de idade e receptor hormonal, o tamanho do tumor, o número de linfonodos acometidos, o grau histológico e o status HER2? O escore ainda adiciona?*

Essa análise foi feita nas duas coortes com dados clínicos mais completos (sueca e britânica). Resultado: mesmo com seis variáveis clínicas no modelo, o escore CorePAM continua adicionando discriminação (valor incremental entre 0,015 e 0,032) com significância estatística forte. Isso sugere que o CorePAM capta **heterogeneidade molecular que não é acessível pelo estadiamento clínico-patológico de rotina**.

20. O resultado de resposta à quimioterapia pré-cirurgia

Análise secundária, com 697 pacientes das quatro coortes neoadjuvantes. O desfecho é resposta patológica completa (ausência de tumor residual após a quimioterapia).

A métrica usada aqui não é razão de risco (porque não há componente temporal; o desfecho é simplesmente sim/não). É **razão de chances** (em inglês, “odds ratio”). Interpretação análoga à razão de risco: razão de chances maior que 1 significa que escores CorePAM mais altos se associam a maior chance de resposta patológica completa.

Coorte	Pacientes	Taxa de resposta	Razão de chances	Área ROC
Houston	182	23,1%	1,44	0,576
Consórcio qualidade	278	20,1%	1,73	0,660
Japonesa	115	23,5%	2,10	0,716
São Francisco	122	26,2%	1,66	0,622
Combinada	697	—	1,69	—

Heterogeneidade (I-quadrado) = 0%. Zero. Os quatro resultados são estatisticamente indistinguíveis entre si — um nível de consistência notável para coortes em plataformas e populações diferentes.

A coorte exploratória I-SPY 2 (986 pacientes, estudo moderno multicêntrico corrigido para efeitos de lote) foi analisada como confirmação independente. O resultado deu razão de chances de 1,68 — praticamente idêntica ao valor combinado. Quando incluída na meta-análise, não muda o número combinado (continua 1,69 com I-quadrado zero).

O que é “área sob a curva ROC”?

Uma métrica alternativa de discriminação para desfechos binários (sim/não). Pense assim: você pega todos os pares de pacientes em que uma respondeu e a outra não. Para quantos pares o escore da respondedora é maior que o da não-respondedora? Essa proporção é a área sob a curva ROC. Mesma escala do índice de concordância (0,5 = acaso, 1,0 = perfeito).

Na coorte japonesa, a área foi 0,716 — considerada razoável. Na coorte de Houston, 0,576 — modesta. O achado combinado (razão de chances 1,69, altamente significativa) é mais robusto que qualquer área individual.

Comentário importante — por que resposta à quimioterapia interessa?

Resposta patológica completa é um **marcador precoce** de bom prognóstico de longo prazo. Em pacientes com câncer de mama triplo-negativo ou HER2-positivo, conseguir resposta completa após quimioterapia pré-cirurgia está associado a taxas de cura significativamente maiores. Por isso, prever quem vai responder ajuda a guiar a decisão de fazer ou não a quimioterapia antes da cirurgia, e com qual regime.

O CorePAM, sendo originalmente um escore de prognóstico (não de predição de resposta), surpreendentemente também mostrou sinal nessa segunda tarefa. Isso é consistente com a intuição biológica: tumores com perfil mais “proliferativo” tendem tanto a ser mais agressivos (prognóstico) quanto a responder mais a quimioterapia (que ataca células em divisão).

20B. O paradoxo estatístico — por que menos genes podem ser mais informativos

Um leitor atento percebe algo aparentemente contra-intuitivo no resultado da comparação direta vinte e quatro contra quarenta e nove genes: o modelo com menos genes foi superior em três das quatro coortes externas. Como pode um modelo que usa **menos** informação discriminar melhor do que um que usa **mais**?

A resposta vem de um princípio fundamental da estatística chamado **compromisso entre viés e variância** (em inglês, *bias-variance tradeoff*). Vale a pena explicá-lo com cuidado, porque é uma das ideias mais úteis de toda a ciência de dados.

A analogia do tiro ao alvo

Imagine dois atiradores disparando cinco flechas cada um em um alvo.

- **Atirador A** acerta sempre perto do centro, mas as flechas ficam todas apertadas em uma pequena região ligeiramente abaixo do centro. Ele erra o centro por pouco, mas erra da mesma forma sempre.
- **Atirador B** tem flechas espalhadas por todo o alvo — algumas no centro, outras longe, em todas as direções. Em média, a posição das flechas dele coincide com o centro, mas cada flecha individual está longe.

Qual atirador é melhor? Depende da pergunta.

- Se você só quer prever onde uma próxima flecha vai cair, prefere o Atirador A — você sabe que ela vai cair naquela região apertada.
- Se você quer que as flechas **em média** atinjam o centro, o Atirador B é igual ao A em média, mas com mais imprevisibilidade.

O Atirador A tem **viés alto** (erra o centro sistematicamente) e **variância baixa** (as flechas ficam juntas). O Atirador B tem **viés baixo** (em média acerta o centro) e **variância alta** (cada flecha imprevisível).

Traduzindo para modelos estatísticos

Cada gene que você adiciona ao modelo é como dar ao modelo mais um parâmetro ajustável. Quanto mais parâmetros, mais o modelo consegue se “moldar” aos dados de treino — chegando mais perto de cada ponto observado.

- Modelo com poucos genes = Atirador A: tem viés mais alto (não captura toda a complexidade) mas variância baixa (quando você aplica em dados novos, o desempenho não oscila muito).
- Modelo com muitos genes = Atirador B: tem viés baixo (captura nuances finas) mas variância alta (quando aplicado em dados novos, o desempenho oscila imprevisivelmente, às vezes melhor, às vezes pior).

Por que quarenta e nove genes perdeu para vinte e quatro

Quarenta e nove genes têm quarenta e nove coeficientes para ajustar. Vinte e oito desses genes têm coeficientes pequenos — refletem sinal fraco e são, em boa parte, ruído específico da coorte de treino. Quando o modelo é transportado para uma coorte nova, com outra tecnologia e outra população, esses coeficientes pequenos — que no treino pareciam captar sinal útil — passam a atuar como ruído residual que **degrada** a previsão.

O modelo de vinte e quatro genes, por construção, descartou esses coeficientes pequenos. Ele só carrega os sinais fortes e robustos. Quando vai para uma coorte nova, o desempenho cai menos — e às vezes até sobe, porque agora está livre de ruído de treino.

A moral em uma frase

Em estatística, **simplicidade robusta vence complexidade ajustada demais** em quase todo cenário de generalização. O CorePAM não foi bem-sucedido apesar de ter poucos genes — foi bem-sucedido **porque tem poucos genes**.

Uma consequência metodológica para quem vai construir outras assinaturas

Este resultado sugere um padrão para estudos futuros: **não otimizar o número de genes escolhendo quantos genes você quer, mas deixar os dados dizerem** qual é o número ótimo, via um critério pré-especificado de perda aceitável de desempenho. O CorePAM exemplifica essa filosofia.

20C. A reprodutibilidade até o último gene — o que torna este estudo incomum

Muitos estudos publicados de assinaturas gênicas têm uma falha silenciosa: não dá para refazê-los. As decisões de análise são descritas em texto — “usamos validação cruzada, rodamos elastic-net, tomamos a semente aleatória X” —, mas quando outro pesquisador tenta reproduzir, esbarra em pequenas diferenças: o gerador de números aleatórios da linguagem dele é diferente, a ordem dos pacientes no arquivo dele é outra, os critérios de filtragem ficaram implícitos. O resultado é “perto, mas não idêntico”. Na prática, cada replicação é uma aproximação, não uma reprodução exata.

O estudo CorePAM vai além do padrão da área em três dimensões.

O padrão pré-especificado

Todas as decisões de análise — qual algoritmo, qual critério de parada, qual margem de não-inferioridade, qual definição de evento — foram **escritas antes de os dados externos serem abertos**. Isto está registrado em uma tabela do artigo (a Tabela 3 da versão acadêmica). O pesquisador não teve a oportunidade de ver os resultados externos e ajustar os parâmetros para “deixar mais bonito”. É o equivalente estatístico de mandar o relógio ser calibrado em fábrica: uma vez na rua, não dá para ajustar escondido.

A atribuição de pacientes para grupos por impressão digital

Uma decisão técnica discreta, mas poderosa: a cada paciente da coorte sueca foi atribuído um grupo de validação cruzada (um entre dez) usando uma **função matemática determinística** chamada **algoritmo de impressão digital 256** (em inglês, *SHA-256* — um algoritmo criptográfico que produz uma sequência única a partir do identificador do paciente). Essa função sempre produz o mesmo resultado a partir do mesmo identificador, em qualquer máquina, em qualquer linguagem de programação, para sempre.

Analogia. Imagine que você tem uma sala com mil pacientes e precisa dividi-los em dez grupos. A maneira tradicional é sortear: ler os nomes e jogar uma moeda ou usar um gerador de aleatórios do computador. Se alguém refizer o estudo, o sorteio será outro, porque as moedas caem diferente e os geradores de aleatórios dependem de qual semente a pessoa usou. A maneira reproduzível: pegar o nome do paciente, passar por uma fórmula matemática que sempre produz o mesmo resultado para o mesmo nome, e usar esse resultado para decidir o grupo. Qualquer pessoa, refazendo com o mesmo nome, cai no mesmo grupo. O “sorteio” é idêntico para sempre.

Isso elimina uma fonte quase invisível de variabilidade nos estudos: a dependência da semente aleatória.

O código completo aberto

O código do estudo está público, em repositório aberto, com todos os trinta e seis programas numerados na ordem em que rodam, desde o carregamento dos dados brutos até a geração das tabelas e figuras do artigo. Qualquer pesquisador no mundo, com acesso aos dados públicos da coorte sueca, pode refazer o estudo **bit a bit** — não apenas com resultados similares, mas com os mesmos números exatos.

Moral. Reprodutibilidade é uma propriedade contínua, não um interruptor de “sim ou não”. Podemos medir cada estudo por quão próximo ele fica do ideal de replicabilidade perfeita. O CorePAM mira alto nessa dimensão, por decisão metodológica consciente.

PARTE V — OS 24 GENES, ENTENDIDOS UM POR UM

Os pesos de cada gene no escore CorePAM foram obtidos pelo treinamento do elastic-net na coorte sueca. Lembre: o peso de um gene é “quanto ele contribui para o escore, positiva ou negativamente”. Peso positivo significa “mais expressão desse gene = maior risco”. Peso negativo significa “mais expressão = menor risco” (gene protetor).

Vamos ver cada um dos 24 genes, agrupados por função biológica.

Cluster de proliferação — os que marcam crescimento rápido

Genes cuja expressão alta indica que o tumor está se dividindo depressa. Tumores em divisão rápida tendem a ser mais agressivos.

- **EXO1 (peso positivo, +0,217, o maior peso absoluto do modelo):** produz uma enzima chamada exonuclease 1, envolvida no reparo do DNA durante a divisão celular. Tumores que expressam muito EXO1 estão se dividindo freneticamente.
- **PTTG1 (peso positivo, +0,114):** codifica uma proteína chamada securina, que regula a separação dos cromossomos durante a mitose (a fase em que a célula se divide em duas).
- **CENPF (peso positivo, +0,015):** proteína do centrômero (a região central dos cromossomos), essencial para mitose.
- **MYBL2 (peso negativo, -0,118):** fator de transcrição (molécula que liga e desliga outros genes) associado ao ciclo celular.
- **MYC (peso negativo, -0,042):** um dos oncogenes mais famosos, promove proliferação.

Paradoxo aparente. MYBL2 e MYC são genes **pró-proliferação**. Deveriam ter peso positivo (mais expressão → maior risco). Mas no modelo aparecem com peso negativo. Como explicar?

Solução. O modelo é multivariado. Os genes EXO1 e PTTG1 já captam o sinal de proliferação-risco. MYBL2 e MYC captam o componente **residual** — tumores com MYBL2 alto *sem* EXO1 alto tendem a ser tumores luminais diferenciados (bom prognóstico, MYBL2 normal em tecido luminal ativo sem hiperproliferação). O peso negativo reflete esse efeito residual, não o papel biológico principal do gene.

Analogia. Imagine que você está avaliando carros. “Velocidade máxima” e “aceleração” são fortemente correlacionadas. Se você põe as duas no modelo, uma delas pode ganhar peso pequeno ou até negativo, porque a outra já capturou o sinal principal. O peso na regressão multivariada não é a importância isolada do preditor; é a contribuição **única** dele, depois de descontar o que os outros já explicam.

Cluster luminal — os marcadores de diferenciação mamária

Genes que são tipicamente expressos em células mamárias bem diferenciadas. Expressão alta geralmente indica tumor luminal, de melhor prognóstico.

- **NAT1 (peso negativo, -0,205, segundo maior peso absoluto):** N-acetiltransferase 1, enzima metabólica marcadora de diferenciação luminal.
- **ESR1 (peso positivo, +0,040):** o gene do receptor de estrogênio alfa em si. Peso **positivo** é contra-intuitivo (ER+ geralmente significa bom prognóstico). Mas, em modelo multivariado com PGR, BCL2 e NAT1 já capturando o “sinal luminal”, ESR1 capta o componente de ER alto com resposta hormonal falha (tumores luminais resistentes).
- **PGR (peso negativo, -0,026):** receptor de progesterona. Perda de PGR em tumores ER+ indica desdiferenciação e pior prognóstico.
- **BCL2 (peso negativo, -0,010):** inibidor de apoptose (morte celular programada). Paradoxalmente, em câncer de mama, BCL2 alto é marcador de bom prognóstico, porque se correlaciona com perfil luminal-diferenciado.
- **MLPH (peso negativo, -0,010):** melanofilina, proteína do transporte intracelular, marcador luminal.

Cluster basal — os marcadores de fenótipo agressivo

Genes tipicamente expressos em tumores basais, que são mais agressivos.

- **FOXC1 (peso positivo, +0,072):** fator de transcrição “forkhead”, marcador forte de tumores basais e triplo-negativos.
- **KRT5 (peso negativo, -0,028):** citoqueratina 5, estrutural, marcador de células basais.
- **KRT17 (peso negativo, -0,016):** citoqueratina 17, outro marcador basal.

Nota. KRT5 e KRT17 têm peso negativo mesmo sendo marcadores basais. Mesma explicação: FOXC1 já captou o “sinal basal-risco” principal; as citoqueratinas captam o componente residual (tumores com citoqueratina alta sem FOXC1 alto podem ser formas mioepiteliais menos agressivas).

Cluster HER2 — os marcadores de superexpressão HER2

Genes associados à via HER2, uma das principais em câncer de mama.

- **ERBB2 (peso negativo, -0,008):** o gene do receptor HER2 em si. Em câncer de mama moderno, HER2-positivo é tratável com remédios específicos (trastuzumabe), o que muda seu prognóstico. No modelo multivariado, o peso pequeno reflete que o efeito biológico de HER2 está sendo capturado também por ERBB2-associados.
- **GRB7 (peso negativo, -0,005):** proteína adaptadora co-amplificada com ERBB2 (estão lado a lado no cromossomo).
- **MIA (peso negativo, -0,119):** “atividade inibidora de melanoma” — apesar do nome histórico, é marcador de diferenciação também em mama.

Outros genes — funções diversas

- **BLVRA (peso negativo, -0,185, terceiro maior peso absoluto):** biliverdina redutase, enzima do metabolismo do heme, antioxidante.
 - **ACTR3B (peso negativo, -0,141):** proteína relacionada à actina, dinâmica do citoesqueleto.
 - **MDM2 (peso negativo, -0,107):** regulador da proteína supressora tumoral p53. Paradoxalmente protetor no modelo; o contexto multivariado explica.
 - **SFRP1 (peso negativo, -0,091):** antagonista da via de sinalização Wnt, função supressora tumoral.
 - **GPR160 (peso negativo, -0,084):** receptor acoplado a proteína G, função em mama pouco caracterizada.
 - **PHGDH (peso positivo, +0,062):** enzima da via de síntese de serina, associada a metabolismo proliferativo.
 - **CXXC5 (peso positivo, +0,027):** regulador epigenético que se liga a sequências CpG.
 - **FGFR4 (peso positivo, +0,011):** receptor do fator de crescimento de fibroblastos 4, sinalização de crescimento.
-

21. Os 26 genes que ficaram de fora

Dos 50 genes originais, 26 **não** entraram no CorePAM porque o elastic-net zerou os pesos deles (a regularização cortou por redundância). Isso significa que o sinal prognóstico que esses genes carregavam já está presente nos 24 selecionados, via genes correlacionados.

Analogia. Em uma equipe de vendas, se você já tem o João, a Maria e o Pedro cuidando da região Sudeste, a contratação de um quarto vendedor para a mesma região adicionaria custo sem ganho real. O algoritmo “demitiu” os 26 genes redundantes.

Entre os excluídos estão alguns nomes famosos do câncer de mama, como BIRC5 (também conhecido como survivin) e MKI67 (o famoso marcador Ki-67). **Por que saíram?** Porque seus sinais estão capturados pelos genes de proliferação que permaneceram (EXO1, PTTG1, CENPF, MYBL2). Não é que eles sejam inúteis — é que são **redundantes** no contexto do painel reduzido.

PARTE VI — LIMITAÇÕES E CAVEATS

A honestidade intelectual do estudo se mede pelo quão explicitamente os autores listam as limitações. No CorePAM, elas estão organizadas em três blocos.

22. Limitações do desenho do estudo

1. **Dados retrospectivos, de bancos públicos.** Nenhuma coorte foi coletada especificamente para este estudo. Isso é eficiente (evita recrutamento, reduz custo) mas herda os vieses de seleção dos bancos originais.

2. **Coorte americana com seguimento curto.** 2,7 anos médios em um câncer com mortalidade típica em 5–15 anos significa que o sinal prognóstico é necessariamente atenuado.
3. **Coorte britânica com desfecho diferente.** A sobrevida específica por câncer não é a mesma métrica que a sobrevida global das outras coortes — isso introduz heterogeneidade inevitável na meta-análise.
4. **Heterogeneidade moderada (I-quadrado = 38,2%).** Embora com fonte identificada, é uma heterogeneidade real que relativiza a precisão da estimativa combinada.

23. Limitações das escolhas analíticas

1. **Modelo clínico basal minimalista.** Só idade e receptor de estrogênio. Não inclui tamanho do tumor, linfonodos, grau. A escolha foi pré-especificada para garantir consistência cross-coorte (nem todas as coortes têm todos os dados clínicos), mas críticos podem argumentar que um modelo basal mais rico seria mais justo.
2. **Padronização intra-coorte como padrão primário.** O artigo reporta resultados principais com z-score intra-coorte (média e desvio calculados dentro da coorte de validação). O esquema “congelado”, mais realista clinicamente, é apresentado como análise secundária.
3. **Esquema congelado depende da plataforma.** Funciona muito bem em sequenciamento e em microarranjo Illumina; atenua em Affymetrix. Isso significa que uso clínico exigirá recalibração específica por plataforma.
4. **Cobertura de genes nem sempre é completa.** A coorte de Estocolmo tinha só 21/24 genes mapeáveis. O escore se ajusta automaticamente (renormaliza pelo denominador), mas ainda assim há perda teórica de informação.

24. Limitações da tradução clínica

1. **Validação analítica fora do escopo.** “Validação analítica” é o processo de demonstrar que um ensaio laboratorial específico mede com precisão e reprodutibilidade o que promete medir. Isso é obrigatório para uso clínico. O CorePAM não fez validação analítica porque usou dados de pesquisa, não um ensaio comercial.
 2. **Calibração necessária por plataforma.** Embora a ordenação de pacientes (discriminação) seja preservada cross-plataforma, a tradução para “probabilidade absoluta de morte em X anos” exige recalibração específica.
 3. **Nenhuma alegação sobre substituir testes comerciais.** O CorePAM **não** é uma alternativa direta ao Prosigna. É uma demonstração de viabilidade científica de reduzir o painel. Ensaios clínicos prospectivos, com comparação direta contra padrão de cuidado, seriam necessários antes de qualquer uso clínico.
-

PARTE VII — PERGUNTAS DE BANCA, COM RESPOSTAS DIDÁTICAS

Esta seção antecipa perguntas que examinadores podem fazer e oferece respostas didáticas — tão claras que qualquer membro da banca, mesmo de fora da área específica, vai compreender.

25. Bloco metodológico

Pergunta: “Por que usar elastic-net, e não apenas LASSO?”

Resposta: LASSO é a regularização que zera pesos, selecionando genes. Mas quando genes são correlacionados — como os genes de proliferação celular, que se ativam em grupo — o LASSO seleciona um deles meio arbitrariamente e ignora o resto. Isso torna a seleção **instável**: uma pequena mudança nos dados pode levar a um painel diferente. O elastic-net combina LASSO com regularização Ridge (que distribui peso entre genes correlacionados), dando uma seleção mais estável. Evidência da estabilidade: em teste de reamostragem com 200 rodadas, 15 dos 24 genes aparecem em mais de 70% das rodadas; 2 genes (ACTR3B e NAT1) aparecem em 100% das rodadas.

Pergunta: “Por que não usar redes neurais profundas ou random forest?”

Resposta: Quatro razões principais. Primeira: **interpretabilidade**. O elastic-net produz um coeficiente para cada gene; você pode explicar o modelo gene a gene. Redes neurais são caixas-pretas. Segunda: **seleção embutida**. O elastic-net já seleciona genes automaticamente via regularização. Outros métodos exigem passos extras. Terceira: **reprodutibilidade**. Random forest e redes neurais têm muitos hiperparâmetros escondidos e sensibilidade a sementes aleatórias. O elastic-net com parâmetros pré-especificados é determinístico. Quarta: **tamanho da amostra**. Três mil pacientes com 50 genes é o terreno onde regressão penalizada brilha. Redes profundas exigem dezenas a centenas de milhares de amostras para superar métodos lineares.

Pergunta: “A margem de não-inferioridade de 0,010 não é arbitrária?”

Resposta: Toda margem é, em última análise, uma escolha. A defesa dela tem três camadas. Primeira: **foi pré-especificada**. Diferente de escolher depois de ver os dados (o que seria circular), a margem foi definida antes. Segunda: **base estatística**. O valor 0,010 é menor que metade do erro padrão estimado do próprio índice de concordância (aproximadamente 0,026). Uma diferença de 0,010 está dentro da incerteza da medida — é estatisticamente indistinguível de zero. Terceira: **análise de sensibilidade**. Os autores mostraram o que aconteceria com margens de 0,005 (resultando em 31 genes), 0,015 (18 genes) e 0,020 (16 genes). A conclusão geral (é possível reduzir o painel substancialmente) se mantém em toda a faixa.

Pergunta: “Por que validação cruzada em 10 folds e não deixar-um-fora?”

Resposta: Deixar-um-fora significa treinar o modelo 3.069 vezes (uma para cada paciente sueca), deixando uma paciente de fora por vez. Computacionalmente caro e, em modelos de sobrevida, tem variância muito alta (dá estimativas instáveis). A validação em 10 folds é o padrão da literatura (Hastie, Tibshirani e Friedman, três estatísticos-referência, recomendam explicitamente). Com 3.069 pacientes, cada fold tem cerca de 307 — tamanho suficiente para estimativa estável.

Pergunta: “Qual a relação entre função de resumo criptográfico SHA-256 e validação cruzada?”

Resposta: É uma solução elegante para reprodutibilidade. Em validação cruzada tradicional, o fold de cada paciente é decidido por sorteio aleatório, controlado por uma semente (um número que inicia o gerador aleatório). O problema: diferentes pesquisadores usam sementes diferentes,

e chegam a folds diferentes, e eventualmente a painéis diferentes. A solução é trocar o sorteio aleatório por um **processo determinístico baseado no próprio número de identificação da paciente**. A função SHA-256 transforma cada número de identificação em um código único e reproduzível. Esse código decide o fold. Qualquer pessoa em qualquer computador, partindo dos mesmos identificadores, monta exatamente os mesmos folds. Zero ambiguidade.

Pergunta: “A padronização intra-coorte não é um problema? Na clínica você tem uma paciente, não uma coorte.”

Resposta: Exatamente por isso fizemos a análise com padronização congelada. A padronização intra-coorte é o framework padrão para validação retrospectiva multi-coorte — é como a literatura faz. A padronização congelada simula deployment clínico real: usa a média e o desvio padrão da coorte de derivação (sueca) como constantes fixas, aplicáveis a qualquer paciente futura. O teste mostrou que o esquema congelado funciona quase idêntico em sequenciamento (diferença no índice de concordância menor que 0,001) e em microarranjo Illumina (diferença menor que 0,001), mas atenua em Affymetrix (aproximadamente -0,04). Essa dependência de plataforma está declarada como limitação explícita.

Pergunta: “E se eu adicionar ou remover genes?”

Resposta: A fronteira de Pareto mostra platô após cerca de 15 genes — o ganho marginal de adicionar genes cai muito rápido. De 24 para 50 genes, ganha-se só 0,009 no índice de concordância (a margem pré-especificada). Remover genes: foi feita análise “deixar-um-gene-de-fora” para cada um dos 24. O impacto máximo foi 0,044 — nenhum gene isolado é “essencial a ponto de o modelo quebrar sem ele”. Isso confirma robustez do painel.

26. Bloco estatístico

Pergunta: “O I-quadrado de 38,2% não é um problema?”

Resposta: Heterogeneidade moderada (que é o rótulo padrão para I-quadrado entre 25% e 75%), sim. Mas três pontos defendem o achado. Primeiro: **fonte identificada**. A maior parte da heterogeneidade vem do fato de a coorte britânica usar sobrevida específica por câncer, enquanto as outras usam sobrevida global. Quando os autores substituem o desfecho britânico por sobrevida global (análise de sensibilidade), o I-quadrado muda, confirmando a origem. Segundo: **direção consistente**. Todas as quatro coortes têm razão de risco maior que 1. A dúvida reside na magnitude, não no sinal. Terceiro: **análise de sensibilidade de Hartung-Knapp**. É uma variante conservadora da meta-análise, pensada para quando há poucos estudos (como aqui, K=4). Mesmo com essa análise mais rigorosa, o resultado combinado permanece significativo.

Pergunta: “Índice de concordância de 0,62 a 0,66 é bom?”

Resposta: Em contexto clínico de câncer de mama, sim. Três comparações relevantes: Primeira: **o Prosigna comercial** atinge índices de concordância tipicamente entre 0,62 e 0,70 em coortes similares. O CorePAM está nessa faixa. Segunda: **o índice isolado não é o único critério**. O valor incremental (o quanto o escore adiciona sobre o modelo clínico básico) é mais informativo e mostra CorePAM agregando 0,030 a 0,094 — ganhos clinicamente perceptíveis. Terceira: **mesmo com 6 variáveis clínicas** (idade, receptor hormonal, tamanho, linfonodos, grau, HER2) já no modelo, o CorePAM ainda adiciona discriminação na coorte britânica de pacientes com

receptor de estrogênio positivo (valor incremental de 0,032). Isso significa que ele capta informação molecular não contida nas variáveis clínicas tradicionais.

Pergunta: “As calibrações com inclinações de 1,57 a 2,74 não mostram que o modelo é ruim?”

Resposta: Elas mostram que o modelo é **sub-confiante** (em inglês, “under-confident”): subestima riscos extremos. Isso é esperado e não é falha do sinal prognóstico.

Por quê. Calibração mede se, quando o modelo diz “30% de chance de morte em 5 anos”, de fato 30% das pacientes com essa predição morrem. A inclinação da calibração deve ser 1 no ideal. Inclinações maiores que 1 indicam que as predições extremas (muito altas ou muito baixas) são mais extremas do que o observado — o modelo é cauteloso demais na faixa do meio.

Isso acontece porque o z-score é intra-coorte. Quando você transporta o modelo de uma população (sueca) para outra (britânica), a escala absoluta muda. A ordenação (índice de concordância) é preservada, mas as probabilidades absolutas precisam de recalibração específica para a nova população.

Analogia. Um termômetro que mede corretamente “quem está mais quente que quem” em uma turma de crianças pode precisar de ajuste de escala ao ser usado em outra turma onde a temperatura ambiente é diferente. Discriminação boa, calibração precisa de recalibração.

27. Bloco biológico

Pergunta: “Se o CorePAM só funciona em receptor de estrogênio positivo, por que incluir negativos na análise?”

Resposta: Cinco pontos. Primeiro: **a coorte de derivação inclui todos os subtipos.** Excluir receptor negativo seria uma seleção post-hoc (depois de ver os dados), o que viola o princípio de pré-especificação. Segundo: **o artigo reporta honestamente.** Sinal forte em receptor de estrogênio positivo (razão de risco entre 1,59 e 1,92 nas coortes), ausente em receptor de estrogênio negativo bem-powered (na coorte britânica com 186 eventos em receptor negativo, razão de risco = 0,97). Terceiro: **na coorte sueca,** o receptor negativo mostra razão de risco = 2,53, *mas* com apenas 35 eventos e intervalo de confiança largo de 3,44 unidades.

Estatisticamente instável. Quarto: **consistência com a literatura.** OncotypeDX e Prosigna (os principais testes genômicos comerciais) também são primariamente indicados em receptor de estrogênio positivo. O padrão do CorePAM segue o da classe. Quinto: **biologia.** Os genes retidos no CorePAM são predominantemente luminais (ESR1, PGR, NAT1, BCL2) e de proliferação. Estes são exatamente os que captam melhor a biologia de tumores receptor positivos.

Pergunta: “Os pesos contra-intuitivos — MYBL2 negativo, ESR1 positivo — fazem sentido?”

Resposta: Sim, em contexto multivariado. Modelos multivariados como elastic-net atribuem pesos que refletem a contribuição **única** de cada gene, depois de descontar o que os outros 23 já explicam.

MYBL2 negativo. MYBL2 é um gene pró-proliferação e deveria aumentar o risco. Mas EXO1 e PTTG1 (também pró-proliferação) já estão no modelo com pesos positivos fortes, e eles

capturam a maior parte do sinal de proliferação-risco. O que sobra para MYBL2 é o componente residual: tumores com MYBL2 alto *sem* EXO1 alto tendem a ser luminais diferenciados, com proliferação “normal” e bom prognóstico. Por isso o peso negativo, que é sinal residual, não biológico principal.

ESR1 positivo. Receptor de estrogênio positivo é, em geral, bom prognóstico. Mas no contexto multivariado com PGR, BCL2 e NAT1 já capturando o sinal luminal-protetor, ESR1 capta o componente de expressão alta do receptor de estrogênio em tumores com **falha de resposta hormonal** — os tumores luminais resistentes, que expressam muito receptor mas não respondem clinicamente. Esses têm prognóstico pior. O peso positivo captura esse fenômeno.

Analogia. Em uma banda de rock, o vocalista e o guitarrista principal brigam pelo protagonismo. Se você pergunta “quanto cada um contribui para a qualidade do show?”, a resposta multivariada dá a contribuição **única** de cada um — descontando o que o outro já proporciona. Um vocalista pode parecer “contribuir negativamente” porque o guitarrista já cobre o espaço.

28. Bloco clínico

Pergunta: “Qual a vantagem prática de 24 versus 50 genes?”

Resposta: Três vantagens principais. Primeira: **custo**. Plataformas como RT-qPCR multiplexado (uma tecnologia mais acessível do que a NanoString nCounter do Prosigna) podem medir 24 genes com custo significativamente menor. Segunda: **qualidade de material**. Material mais degradado (por exemplo, blocos de tecido em parafina guardados por anos, comum em arquivos de patologia brasileira) pode ser suficiente para medir 24 alvos com qualidade, enquanto 50 alvos exigem mais RNA íntegro. Terceira: **logística**. Um painel menor exige menos validação analítica laboratorial, reduzindo o custo e o tempo de desenvolvimento de um ensaio clínico.

Mas — cuidado. O artigo não demonstra nenhuma dessas vantagens na prática. Demonstra a *viabilidade científica* da redução. O desenvolvimento de um ensaio clínico real exige trabalho complementar.

Pergunta: “Isso muda a conduta clínica hoje?”

Resposta: Não. O CorePAM é um estudo de validação retrospectiva baseado em dados públicos. Para mudar conduta clínica seriam necessários: Primeiro: **validação analítica** de um ensaio laboratorial específico em plataforma definida (RT-qPCR, sequenciamento direcionado, etc.). Segundo: **validação clínica prospectiva** em coortes coletadas especificamente para testar o ensaio. Terceiro: **comparação direta** contra o padrão de cuidado (Prosigna, OncotypeDX) em ensaio clínico randomizado. Quarto: **avaliação de custo-efetividade** em contexto específico (por exemplo, sistema de saúde brasileiro).

O CorePAM posiciona 24 genes como **candidato** para esse pipeline de desenvolvimento, não como solução pronta.

Pergunta: “A coorte sueca é generalizável para o Brasil?”

Resposta: O sueco é predominantemente europeu branco, sim. Mas a validação usa coortes diversas: americana (multicêntrica, com mais diversidade étnica), britânica/canadense (multi-étnica), taiwanesa (população do leste asiático), Estocolmo (outra coorte europeia). Razões de

risco consistentes entre três continentes sugerem robustez. Uma validação em coorte brasileira seria um próximo passo natural e poderia ser a principal contribuição original dessa tese de doutorado, dado que o Brasil tem características populacionais particulares (miscigenação, distribuição etária, acesso ao diagnóstico em fases diferentes do ciclo) que merecem validação específica.

29. Bloco de reprodutibilidade e ética

Pergunta: “Como sei que os resultados são reprodutíveis?”

Resposta: Seis camadas de reprodutibilidade. Primeira: **dados públicos**. Todas as coortes estão disponíveis em bancos online (GEO, cBioPortal, Genomic Data Commons). Segunda: **código aberto**. Todo o código do estudo está em repositório público do GitHub. Terceira: **folds determinísticos**. Função SHA-256, já explicada na seção 7 acima. Quarta: **parâmetros congelados**. Documento público registrando as decisões analíticas antes da execução. Quinta: **afirmações contra codificação rígida**. O código tem verificações automáticas de que os valores reportados no artigo vêm de arquivos-fonte, não estão digitados manualmente (o que eliminaria erro de transcrição). Sexta: **hashes criptográficos dos outputs**. Cada arquivo intermediário tem seu hash registrado, de forma que qualquer alteração posterior é detectável.

Pergunta: “Foi usada inteligência artificial — como garantir que não há viés?”

Resposta: O assistente Claude, da Anthropic, foi usado como **ferramenta computacional** — para organização de diretórios, escrita de código auxiliar e formatação de texto. Nenhuma decisão analítica ou interpretativa foi delegada à IA. Todo código foi revisado e validado pelo pesquisador principal. A IA nunca viu os dados de pacientes: ela ajudou a escrever o código que **processa** os dados, mas não teve acesso aos dados em si.

Pergunta: “Ética — dados públicos precisam de aprovação do comitê de ética?”

Resposta: Não. Dados exclusivamente públicos, previamente desidentificados (nenhum identificador de paciente original disponível), com aprovações éticas das coortes originais. Nenhum dado novo de sujeitos humanos foi coletado neste estudo. No manuscrito, consta explicitamente: “Não aplicável” para aprovação ética e consentimento informado.

PARTE VIII — O ESTUDO CORE-PAM NO CONTEXTO DA TESE DE DOUTORADO

30. O que este estudo contribui de original

Quatro contribuições que justificam defesa como tese de doutorado:

Contribuição metodológica. O CorePAM é, dentro do conhecimento do autor, o primeiro estudo a aplicar redução baseada em dados do painel de 50 genes com quatro características simultâneas: - Critério de não-inferioridade pré-especificado. - Folds determinísticos via função

de resumo criptográfico. - Fronteira de Pareto para seleção do número de genes (sem pré-especificação). - Validação cross-platform em múltiplas tecnologias.

Cada uma dessas características isoladamente existe na literatura. A combinação integrada em um único estudo é a contribuição metodológica central.

Contribuição empírica. Demonstração de que 24 genes retêm a essência prognóstica dos 50. A comparação direta “24 genes versus 49 genes” mostrou 24 genes **superior** em 3 de 4 coortes externas. Esse achado surpreendente, suportado por base estatística sólida (regularização, parsimônia), é um resultado original que abre portas para desenvolvimento de ensaios mais acessíveis.

Contribuição de duplo desfecho. Validação simultânea para prognóstico (sobrevida global ou específica) e predição de resposta à quimioterapia pré-cirurgia. Encontrar razão de chances poolada de 1,69 com heterogeneidade zero em 697 pacientes é um achado secundário forte, consistente com a intuição biológica de que perfil proliferativo prediz ambos.

Contribuição de ciência aberta. Pipeline totalmente reproduzível, parâmetros congelados, verificações anti-codificação rígida. Exemplo prático de como pesquisa em oncologia genômica pode ser feita de forma transparente e auditável, com dados e código abertos.

31. Estrutura possível da tese

Capítulo 1 — Introdução. Câncer de mama em dimensão epidemiológica, molecular e clínica. Classificação por subtipos intrínsecos. Testes genômicos comerciais. Gap de acesso em sistemas públicos de saúde, especialmente no sistema brasileiro. Justificativa da redução do painel de 50 genes.

Capítulo 2 — Revisão de literatura. Subtipos moleculares (Perou 2000, Sorlie 2001, Parker 2009). Utilidade clínica dos testes genômicos (TAILORx, MINDACT, RxPONDER — estudos clínicos que validaram o OncotypeDX e o MammaPrint). Métodos de seleção de genes em estatística. Reduções previamente tentadas do painel de 50 genes, com análise crítica de por que falharam. Meta-análise de assinaturas prognósticas. Contexto dos testes genômicos no Brasil, na rede pública e privada.

Capítulo 3 — Objetivos. Objetivo geral: derivar e validar a menor redução não-inferior do painel de 50 genes. Objetivos específicos: (1) definir o arcabouço metodológico pré-especificado; (2) derivar o CorePAM a partir da coorte sueca; (3) validar em quatro coortes externas; (4) avaliar predição de resposta à quimioterapia pré-cirurgia; (5) comparar diretamente com o modelo de 49 genes.

Capítulo 4 — Metodologia. Expandir o que está no artigo para nível de tese: design do estudo segundo o guideline TRIPOD; descrição detalhada de cada coorte; preprocessamento de expressão (mais tecnicidade do que o artigo); derivação matemática do elastic-net; formulação do z-score congelado; modelo de meta-análise de efeitos aleatórios; software e arquitetura de reprodutibilidade.

Capítulo 5 — Resultados. Todos os resultados do artigo, com figuras em tamanho grande, tabelas completas, e análises de sensibilidade detalhadas.

Capítulo 6 — Discussão. Contextualização no cenário brasileiro. Comparação detalhada com Prosigna, OncotypeDX, MammaPrint. Implicações para implementação no sistema público de saúde. Estimativa de custos comparativos entre RT-qPCR multiplexado e NanoString nCounter. Próximos passos para validação prospectiva e desenvolvimento de ensaio.

Capítulo 7 — Conclusões e perspectivas futuras. Validação em coorte brasileira (Hospital do Câncer? Registro Hospitalar de Câncer?). Desenvolvimento de ensaio RT-qPCR específico. Avaliação de custo-efetividade. Validação prospectiva.

Apêndices. Artigo submetido, código completo, parâmetros congelados, hashes de reprodutibilidade, material suplementar.

32. O que expandir além do artigo

O artigo é deliberadamente enxuto, para caber nas páginas da revista. A tese pode aprofundar:

Contexto do sistema público brasileiro. Portaria 874/2013 do Ministério da Saúde (Política Nacional de Prevenção e Controle do Câncer). Papel da Comissão Nacional de Incorporação de Tecnologias no sistema público. Acesso atual a testes genômicos no Brasil (realidade: extremamente limitado).

Custo comparativo detalhado. Desenvolvimento de ensaio RT-qPCR multiplexado de 24 genes: custo estimado por amostra, custo de implementação em laboratório público, tempo de desenvolvimento. Comparação com Prosigna (3.500 dólares por amostra + equipamento dedicado + reagentes proprietários).

Epidemiologia brasileira de câncer de mama. Dados do INCA (Instituto Nacional de Câncer). Distribuição de subtipos moleculares em população brasileira, quando disponível. Particularidades de diagnóstico em fases mais avançadas, em regiões de menor acesso.

Arcabouço regulatório. Regulamentação da Agência Nacional de Vigilância Sanitária para ensaios moleculares. Padronização e controle de qualidade laboratoriais.

Validação em coorte brasileira. Se houver coorte pública disponível (por exemplo, tecidos bancados em hospitais oncológicos brasileiros), replicar as análises principais do CorePAM. Esse seria o principal componente original da tese.

PARTE IX — REFERÊNCIAS ACADÊMICAS ESSENCIAIS

Esta seção não é exaustiva (o artigo tem dezenas de referências). Lista só as que sustentam os conceitos centrais, para que você possa ler as fontes primárias.

Referência	O que estabeleceu	Papel no CorePAM
Perou e colaboradores, 2000	Descoberta dos subtipos moleculares de câncer de	Fundação conceitual do PAM50

Referência	O que estabeleceu	Papel no CorePAM
	mama por expressão gênica	
Parker e colaboradores, 2009	Definição dos 50 genes do painel PAM50 e do escore de risco de recidiva	Define o painel original que o CorePAM reduz
Nielsen e colaboradores, 2014	Validação analítica do Prosigna (NanoString)	Referência comercial — CorePAM não se compara diretamente com ela
Zou e Hastie, 2005	Método elastic-net combinando LASSO e Ridge	Fundamento matemático do modelo CorePAM
Harrell e colaboradores, 1982	Proposta do índice de concordância para modelos prognósticos	Métrica primária do estudo
Viechtbauer, 2010	Pacote metafor para meta-análise em R	Ferramenta estatística da síntese do CorePAM
Sparano e colaboradores, 2018	Estudo TAILORx, validando o OncotypeDX em decisão de quimioterapia	Contexto clínico: testes genômicos em decisão terapêutica
Cardoso e colaboradores, 2016	Estudo MINDACT, validando o MammaPrint	Contexto: ensaio de 70 genes validado clinicamente
Moons e colaboradores, 2015	Guideline TRIPOD para modelos prognósticos	Padrão seguido pelo CorePAM
Brueffer e colaboradores, 2018	Descrição da coorte sueca de derivação	Coorte-base do CorePAM
Curtis e colaboradores, 2012	Descrição da coorte britânica/canadense	Maior coorte externa de validação
Cancer Genome Atlas Network, 2012	Descrição molecular do câncer de mama na coorte americana	Coorte externa
Kao e colaboradores, 2011	Descrição da coorte taiwanesa	Coorte externa
Pawitan e colaboradores, 2005	Descrição da coorte de Estocolmo	Coorte externa (menor)

ENCERRAMENTO — REVENDO OS PRINCIPAIS CONCEITOS EM TRÊS PÁGINAS

Se você leu até aqui, já tem o arcabouço completo. Vamos amarrar as ideias.

O problema

Câncer de mama tem cinco subtipos moleculares. O painel comercial de 50 genes (Prosigna) ajuda na decisão clínica, mas custa mais de três mil dólares por paciente e exige equipamento dedicado. Isso bloqueia acesso em sistemas de saúde como o brasileiro.

A pergunta

É possível usar menos genes e ainda prever tão bem quanto? Se sim, abre-se a porta para testes mais baratos, em plataformas comuns.

O método

Treinar um modelo estatístico (regressão de Cox com regularização elastic-net) na maior coorte pública de câncer de mama com sequenciamento de RNA (a sueca, com 3.069 pacientes). Usar validação cruzada em dez folds, com folds determinísticos (via função de resumo criptográfico SHA-256 dos identificadores). Para cada valor possível do parâmetro de regularização, contar genes selecionados e medir índice de concordância. Traçar a fronteira de Pareto e escolher o menor número de genes dentro de uma margem pré-especificada (0,010) do máximo desempenho.

O resultado da derivação

24 genes selecionados. Índice de concordância de 0,670 com 24 genes, versus 0,679 com 50 genes. Diferença: 0,009. Dentro da margem.

Os 24 genes

Repartidos por função biológica: 5 de proliferação (EXO1, PTTG1, CENPF, MYBL2, MYC), 5 luminais (NAT1, ESR1, PGR, BCL2, MLPH), 3 basais (FOXC1, KRT5, KRT17), 3 associados a HER2 (ERBB2, GRB7, MIA) e 8 de funções diversas (BLVRA, ACTR3B, MDM2, SFRP1, GPR160, PHGDH, CXXC5, FGFR4).

A validação

Quatro coortes externas, em três continentes, em quatro tecnologias diferentes. Razões de risco positivas e significativas em todas (1,20 a 1,71). Meta-análise combinada: razão de risco 1,37, intervalo 1,24-1,52, valor-p extremamente pequeno, heterogeneidade moderada (38%) com fonte identificada (diferença de desfecho na coorte britânica).

A comparação direta 24 vs 49

Em três de quatro coortes externas, o modelo de 24 genes superou o modelo de 49 genes. O menor generaliza melhor — consequência matemática da parcimônia.

O valor incremental

Mesmo após ajustar por idade e receptor de estrogênio, o escore adiciona entre 0,030 e 0,094 no índice de concordância. Mesmo após ajustar por seis variáveis clínicas, adiciona 0,015 a 0,032. O escore capta informação molecular não contida no estadiamento clínico de rotina.

A análise secundária

Em 697 pacientes com quimioterapia pré-cirurgia, razão de chances combinada de 1,69 para resposta patológica completa, com heterogeneidade zero. Consistência notável entre quatro coortes em plataformas diferentes.

As limitações declaradas

Dados retrospectivos, coorte americana com seguimento curto, coorte britânica com desfecho distinto (sobrevida específica), z-score congelado dependente de plataforma (funciona em sequenciamento e Illumina, atenua em Affymetrix), e validação analítica de ensaio clínico fora do escopo. Nenhuma alegação de substituir Prosigna; é prova de conceito científica.

A contribuição para a tese

Arcabouço metodológico integrando pré-especificação, determinismo e fronteira de Pareto. Demonstração empírica de redução substancial sem perda prognóstica. Validação de predição de resposta. Pipeline aberto e reproduzível. A extensão natural para a tese é validação em coorte brasileira e desenvolvimento de ensaio RT-qPCR adaptado ao contexto do sistema único de saúde.

Fim do guia. Se uma pergunta da banca te pegar de surpresa, volte à seção relevante. Cada resposta do bloco de perguntas antecipadas já foi construída para ser didática ao examinador externo. Explique como ensinaria a um colega que entrou ontem no laboratório — essa é a atitude que o guia deve cultivar.